感悟报告

Linux部分

第一次接触Linux系统，同时也是第一次直接使用终端。第一关还好，就是一开始没注意input的格式，后面改过来就过了，第二关也一起过了。第三关加空格一开始用的echo结果显示21个字节，问了ai后才知道要用sed，不然空格会在\n后面😅。刚看到第四关的时候人是蒙的，题目都看不懂，问ai才知道，但也写不来，最后还是让ai写了，后面几关也是一样😵，到现在还是没搞明白，争取在面试前弄懂吧，ai还是太好用了😅。

Git部分

git倒是认识，但之前也是用的Vscode的界面，没怎么直接敲过指令。关卡也简单，就是有时候容易忘指令的作用，会去问ai😅。

CUDA部分

第一次接触这玩意，也是第一次知道C++还有这用途。网站容器总是满的，只能本地搭建环境，用的虚拟机，环境ai搭的。第一关用代码复制粘贴就行了，应该是主要入门。第二关开始就要自己写代码了，但也不难，先得到全局下标，在用if (idx < N)防止线程越界就行了。第三关从向量到了矩阵，所以要算计算单元相对于全局的行和列，同时还要用if (row < M && col < N)防止越界，因为CUDA是行主序，所以要用行编号乘以列数加上列编号计算。

第四关开始就不对劲了。这关不光要自己算grid和block，还得把矩阵切块塞进共享内存，两个__syncthreads()我盯了半天才想明白。道理好像懂了，让我自己写还是写不出来。这关起第一次算性能分，我也不知道自己算快还是算慢。

最后一关是三选一，我选了GEMM，理由很简单，前一关的分块矩阵乘就是它的底子，改一改就能起步。真正动手优化的就两件事：一个线程算4×4个输出，这样从共享内存取一次数能用四次，访存比从0.5提到2.0；tile从16×16放大到64×64，全局内存的读取量降到四分之一。但tile也不是越大越好，本机是26个SM，512的矩阵切成64×64正好64个block，再往上放SM就填不满，反而更慢。

环境是最折腾的一块。容器一直满，只能本地搭虚拟机，CUDA前后装了三次，中间磁盘还满了，报了一堆看不懂的错，最后是扩容逻辑卷才解决。虚拟机没有显卡直通，编译能过但跑不起来，第一次跑测试程序直接输出16行FAIL，我人傻了，后来才发现不是代码错——虚拟机里根本没有显卡，cudaMalloc默默失败，输出全是0，所以误差比例全挤在400到1000之间。为了确认逻辑真没问题，又用Python把kernel一步步复刻了一遍，跟朴素三重循环对拍，80组尺寸全过而且每一位都相同，这才敢交。